

Architectures de vision profonde

Reconnaissance, Détection et Segmentation

Plan du cours

- Trois questions, cinq familles de tâches

1 Architectures de classification — CNN, ViT, backbones

2 Détection d'objets — R-CNN, YOLO, DETR, FPN

3 Segmentation sémantique — FCN, U-Net, DeepLab, SegFormer

4 Segmentation d'instances — Mask R-CNN, SOLO, SAM

5 Segmentation panoptique — Mask2Former

6 Récapitulatif — métriques et application aux manuscrits

Introduction

Trois questions, cinq familles de tâches

Trois questions, cinq familles de tâches

Chaque question définit des contraintes sur la sortie du modèle — et donc des choix architecturaux différents

Classification

Quelle classe ?
Étiquette sur l'image
entière
Sortie : vecteur de
probabilités

Détection

Quoi + où ?
Boîte englobante +
classe par objet
Sortie : boîtes + scores

Seg. sémantique

Classe de chaque pixel
Même classe = même
étiquette
Sortie : carte $H \times W \times C$

Seg. d'instances

Instance de chaque pixel
Deux objets = deux
masques
Sortie : masques
binaires

Seg. panoptique

Things + stuff unifiés
Instance + classe par
pixel
Sortie : tout à la fois

Application aux manuscrits médiévaux

Chaque étape du pipeline HTR correspond à une tâche de vision distincte

Tâche dans le pipeline	Paradigme	Modèle utilisé
Classifier une page (texte / illustration / mixte)	Classification	DINOv2 + sonde linéaire
Localiser colonnes, marges, enluminures	Détection / Seg. séman.	SAM
Isoler chaque ligne de texte	Seg. d'instances	Kraken BLLA
Décrire le contenu d'une illustration	Classification multi-label	CLIP
Binariser les pixels d'encre	Seg. sémantique binaire	Sauvola (sans DL)

1. Architectures de classification

Architecture CNN de classification

Deux composants universels : un extracteur de caractéristiques (backbone) et une tête de classification

Backbone — Extracteur de features

Couches convolutives empilées
Réduction progressive de la résolution spatiale
Augmentation de la profondeur sémantique (D canaux)
Sortie : feature map $h \times w \times D$ ($h \ll H$, $w \ll W$)

Tête de classification

Global Average Pooling $\rightarrow$ vecteur (D,)
Couche fully connected : $D \rightarrow n_classes$
Softmax $\rightarrow$ probabilités sur C classes

Global Average Pooling (GAP)

Moyenne spatiale de chaque canal : vecteur (D,)
Indépendant de la taille d'entrée
Remplace les denses FC d'AlexNet/VGG
Réduit considérablement les paramètres

Évolution des architectures — jalons clés

D'ImageNet 2012 au Vision Transformer : innovations cumulatives qui ont façonné le domaine

Architecture	Année	Paramètres	Top-1 ImageNet	Innovation clé
LeNet-5	1998	60 K	—	Paradigme Conv → Pool → FC
AlexNet	2012	60 M	63.3%	ReLU, Dropout, GPU
ResNet-50	2016	25 M	76.1%	Skip connections, profondeur 50→152 couches
EfficientNet-B7	2019	66 M	84.3%	Compound scaling (width × depth × resolution)
ViT-B/16	2020	86 M	81.8%	Patches en tokens + self-attention

2. Détection d'objets

Détecteurs en deux étapes — Famille R-CNN

Principe : séparer la proposition de régions candidates de leur classification

R-CNN (2014)

Selective Search → ~2 000 régions
Chaque région → CNN (AlexNet)
indépendant
Très lent : ~47 s/image
SVM + régression de boîte

Fast R-CNN (2015)

1 seule passe CNN pour l'image entière
RoI Pooling : feature fixe par région
Partage du backbone entre régions
Tête FC : classe + boîte en parallèle

Faster R-CNN (2016)

RPN : Region Proposal Network entraînable
k anchors par position (tailles × ratios)
RPN partagé avec la tête de classification
Référence encore utilisée aujourd'hui

Détecteurs en une étape, Transformer et pyramide de features

Rapidité, robustesse au déséquilibre, et suppression des anchors

YOLO — You Only Look Once (2016)

Grille $S \times S$: chaque cellule prédit B boîtes + C classes
1 seule passe : détection en temps réel
Sortie tenseur ($S, S, B \times 5 + C$)

Focal Loss & RetinaNet (2017)

Déséquilibre foreground/background en 1 étape
 $FL(p_t) = -(1-p_t)^\gamma \log(p_t)$: down-pondère les exemples faciles
 $\gamma=2$: exemples à $p_t=0.9 \rightarrow$ poids réduit à 1%

DETR — Détection par Transformer (2020)

Prédiction directe de N boîtes (pas d'anchors, pas de NMS)
Hungarian matching : affectation bipartite prédictions $\leftrightarrow$ objets
Encodeur-décodeur Transformer sur la feature map

FPN — Feature Pyramid Network (2017)

Construit une pyramide de feature maps multi-résolutions
Combine features bas niveau (haute résolution) + haut niveau (haute sémantique) via connexions latérales
Petits objets détectés à haute résolution (P2/P3) · Grands objets à basse résolution (P4/P5)
Standard de facto dans Faster R-CNN, Mask R-CNN, etc.

3. Segmentation sémantique

FCN et U-Net — architectures fondatrices

Sortie : carte de classe de même résolution que l'image ($H \times W \times C$) · Un label par pixel

FCN — Fully Convolutional Network (2015)

Couches fully connected → convolutions 1×1

Produce une carte de classes basse résolution

Upsampling $\times 32$ pour revenir à la résolution originale

FCN-16s / FCN-8s : skip connections depuis stride 16 et 8

Première architecture de segmentation entièrement convolutive

U-Net (2015) — Encodeur-décodeur

Encodeur (contraction) : conv + maxpool, ↓ résolution

Décodeur (expansion) : upsample + concat skip connection

Skip connections : concaténation features encodeur → décodeur

Préserve l'information de localisation fine dégradée par le pool

Standard de facto pour la segmentation de documents

DeepLab et SegFormer — champ réceptif et Transformers

Deux approches pour capturer le contexte multi-échelle sans perte de résolution

DeepLab v3+ (2017–2018)

Convolutions dilatées (trous) : taux $r \rightarrow$ champ $2r-1 \times 2r-1$ sans paramètres supplémentaires

ASPP : convolutions dilatées en parallèle ($r=6, 12, 18$)

Capture du contexte à multiples échelles

Pas de perte de résolution spatiale

Backbone : ResNet ou Xception pré-entraîné

SegFormer (2021)

Backbone : Mix Transformer (MiT) hiérarchique

Produit des features multi-échelles nativement

Décodeur MLP léger : projection linéaire + upsampling bilinéaire

Aucune convolution dans le décodeur

Plus léger que DeepLab tout en atteignant des performances supérieures

4 & 5. Instances et Panoptique

Segmenter chaque objet individuel, puis unifier

Segmentation d'instances

Associer un masque binaire à chaque instance individuelle — deux objets de même classe = deux masques distincts

Mask R-CNN (2017)

Étend Faster R-CNN : 3ème tête parallèle (tête de masque)
RoI Align remplace RoI Pooling (interpolation bilinéaire, sans arrondi)
FCN 28×28 par instance et par classe
Loss masque calculée uniquement sur la classe correcte k^*

SOLO & SOLOv2 (2020)

Sans détection préalable de boîtes
Grille $S \times S$: chaque cellule = responsable d'une instance
Toutes les instances prédites en parallèle
SOLOv2 : prédiction de masque dynamique plus efficace

SAM — Segment Anything (2023)

Segmentation d'instances promptable (point, boîte, texte)
Zero-shot : jamais entraîné sur manuscrits médiévaux
Entraîné sur 1,1 Md de masques génériques
Force : flexibilité sans annotation de domaine
Pas de sémantique native (pas de labels de classe)

Segmentation panoptique

Unification complète : chaque pixel reçoit une classe ET, pour les objets comptables, une instance

Things vs Stuff

Things (choses) : objets comptables individuels

- Enluminures, lettrines, personnes, voitures
- Traités comme en segmentation d'instances

Stuff (matière) : régions de fond amorphes

- Parchemin, ciel, espace inter-lignes
- Traités comme en segmentation sémantique

Mask2Former (2022) — Architecture de référence

Reformule toutes les segmentations (séman., instances, pano.)

comme un problème de prédiction de masques

Décodeur Transformer : N requêtes apprenables

Cross-attention sur features multi-résolutions

Panoptic Quality (PQ) :

$PQ = \text{Qualité de segmentation} \times \text{Qualité de reconnaissance}$

6. Récapitulatif

Comparaison des familles d'architectures

Sortie, granularité, architecture type et modèle de référence

Famille	Sortie	Architecture	Modèle de réf.
Classification	Vecteur de probas	CNN + GAP + FC	ResNet / ViT
Détection	Boîtes + classes	RPN + tête de détet.	Faster R-CNN / DETR
Seg. sémantique	Carte pixel→classe	Encodeur-décodeur	DeepLab / SegFormer
Seg. d'instances	Masques par instance	Mask R-CNN / SOLO	Mask R-CNN / SAM
Seg. panoptique	Tout (classe+instance)	Transformer multi-masques	Mask2Former

Métriques d'évaluation par tâche

Chaque famille dispose de sa métrique principale adaptée à la nature de sa sortie

IoU

$$\frac{(|A|) \cap (|B|)}{(|A|) \cup (|B|)}$$

Intersection over Union

$$\text{IoU}(A,B) = |A \cap B| / |A \cup B|$$

$\in [0, 1]$

Seuil 0.5 $\rightarrow$ détection
correcte

Utilisée pour détection et
segmentation

mAP — Détection

mean Average Precision

AP par classe = aire sous courbe
précision-rappel
mAP = moyenne des AP sur toutes
les classes

mAP@0.5 : seuil IoU=0.5
mAP@0.5:0.95 : moyenne sur
seuils 0.5–0.95

mIoU — Segmentation sém.

$$\frac{TP}{TP + FP + FN}$$

mean Intersection over Union

IoU par classe : $TP / (TP+FP+FN)$
mIoU = moyenne sur toutes les
classes

Sensible aux classes rares
Métrique standard de
segmentation sém.

Dice

$$\frac{2 \times |TP|}{2 \times |TP| + |FP| + |FN|}$$

= F1-score

$$= 2 \cdot \text{IoU} / (1 + \text{IoU})$$

Plus robuste si classes
très déséquilibrées