

DeepLabv3 et les convolutions dilatées pour la segmentation

Atrous convolution · ASPP · DeepLabv3+ · Comparaison U-Net · Applications SegmOnto

Deux philosophies face au même problème

La tension entre compréhension sémantique et localisation précise — deux réponses architecturales complémentaires

U-Net — compresser puis reconstruire

Comprime l'image jusqu'au bottleneck (profondeur sémantique)
Conserve l'information à chaque niveau par des skip connections
Reconstruit la résolution par upsampling dans le décodeur

Force : précision des contours (bords fins, lignes de baselines)
Limite : contexte multi-échelle limité à la profondeur du réseau

DeepLab — ne pas compresser dès le départ

Refuse de perdre la résolution en premier lieu
Remplace les derniers strides par des convolutions dilatées
Maintient une résolution élevée (stride 8 ou 16 vs 32)

Force : contexte multi-échelle via l'ASPP (local → global)
Limite : contours moins précis sans décodeur (corrigé par v3+)

Complémentarité pour les manuscrits médiévaux

U-Net excelle : structures irrégulières avec bords fins (lignes de texte, polygones de baselines, binarisation des traits d'encre)
DeepLab excelle : contexte multi-échelle déterminant (distinguer lettrine du texte courant, séparer illustration d'une zone de rubrique dans une page enluminée)
DeepLabv3+ unifie les deux : ASPP pour la multi-échelle + skip léger pour les contours → meilleur compromis pour la segmentation de layout
dhSegment (outil de référence) repose sur un hybride ResNet U-Net — la même intuition

1. Le problème de la dégradation de résolution

Stride et pooling — ennemis de la précision de segmentation

Stride, pooling et la question de DeepLab

ResNet-50 standard → output stride 32 → feature map 16×16 pour une image 512×512 — catastrophique pour la segmentation

Le problème — output stride 32

MaxPool 2×2 : ÷2 après chaque bloc
Strided convolution (stride>1) : ÷2 en calculant les features

ResNet-50 : stride cumulé = 32
Image 512×512 → feature map 16×16
= 1 024× moins de positions spatiales

Pour la classification : ✓ pas de problème
→ L'objet occupe la majorité de l'image
→ Pas besoin de localisation pixel fine

Pour la segmentation : ✗ catastrophique
→ Prédicteur sur 16×16 → frontières grossières
→ Upsampling ×32 → carte pixelisée et floue

FCN — tentative de solution (section 2.0)

Skip connections depuis stride 8 et stride 16
Upsampling guidé par l'information intermédiaire

Résultat : meilleur que l'upsampling brut
Mais : reste un processus de reconstruction
→ On essaie de retrouver une précision perdue

La question de DeepLab

Et si on ne réduisait pas autant la résolution dès le départ ?

Peut-on conserver les features à stride 8 (et non 32) tout en maintenant un champ réceptif aussi large que nécessaire pour la compréhension sémantique ?

→ Oui — grâce aux convolutions dilatées

Output stride — le paramètre clé

Output stride = rapport entre résolution d'entrée et résolution finale de la feature map du backbone

ResNet standard : OS = 32
→ Feature map 16×16 pour 512×512

DeepLab OS = 16 :
→ Feature map 32×32 (2× plus grande)
→ Surcoût computationnel modéré

DeepLab OS = 8 :
→ Feature map 64×64 (4× plus grande)
→ Précision maximale, surcoût important

Compromis recommandé : OS=16 pour la plupart des tâches de manuscrits

2. La convolution dilatée (atrous convolution)

Élargir le champ réceptif sans toucher ni la résolution ni les paramètres

Définition et propriétés de la convolution dilatée

$y[i] = \sum x[i + r \cdot k] \cdot w[k]$ · Le taux r définit l'espacement entre les éléments du noyau

La propriété essentielle

Un noyau 3×3 dilaté conserve exactement 9 paramètres quelle que soit la valeur du taux r

Champ réceptif effectif d'un noyau 3×3 avec taux r :

→ $r=1$: noyau  → champ 3×3 (standard)

→ $r=2$: noyau  → champ 5×5

→ $r=4$: noyau  → champ 9×9

→ $r=8$: → champ réceptif 17×17

→ $r=16$: → champ réceptif 33×33

Padding nécessaire pour conserver la résolution :

padding = $r \times \lfloor k/2 \rfloor$ (pour $k=3$: padding = r)

Sans dilatation, obtenir un champ 33×33 demanderait une convolution 33×33 (1089 paramètres vs 9)

Taux r	Champ réceptif	Padding	Note
$r = 1$	3×3	1	Convolution standard
$r = 2$	5×5	2	1 pixel d'espacement
$r = 4$	9×9	4	3 pixels d'espacement
$r = 6$	13×13	6	Branche ASPP (OS=16)
$r = 12$	25×25	12	Branche ASPP (OS=16)
$r = 18$	37×37	18	Branche ASPP (OS=16)

L'astuce DeepLab — remplacer les strides par des dilatations

Intervention chirurgicale sur le backbone ResNet : seuls les derniers blocs sont modifiés

Stratégie — modification minimale du backbone

On ne remplace PAS toutes les convolutions par des convolutions dilatées

On intervient uniquement sur les derniers strides :

ResNet-50 original :

layer1 → stride 4  conservé

layer2 → stride 8  conservé

layer3 → stride 16  conservé pour OS=16

layer4 → stride 32  supprimé → remplacé par dilation=2

Résultat OS=16 :

→ stride final 16 au lieu de 32

→ feature map 32×32 pour une image 512×512

→ 2× plus grande que ResNet standard

Pour OS=8 : aussi modifier layer3 (dilation=2) + layer4 (dilation=4)

→ feature map 64×64 — précision maximale

Modification pour OS=16 (en pratique)

Pour chaque Conv2d avec stride=(2,2) dans layer4 :

m.stride = (1, 1) ← supprimer le stride

m.padding = (2, 2) ← adapter le padding

m.dilation = (2, 2) ← ajouter la dilatation

Reste du backbone inchangé — poids ImageNet toujours utilisables

Coût-bénéfice selon l'output stride

OS=32 (standard) : feature map 16×16

→ Rapide, but cartes de segmentation grossières

OS=16 : feature map 32×32 (+modéré)

→ Compromis recommandé pour la plupart des tâches

OS=8 : feature map 64×64 (++mémoire et temps)

→ Précision maximale sur les contours fins

→ Réservé aux cas où la précision est critique

(binarisation fine, détection de baselines)

3. L'ASPP — multi-échelle par convolutions parallèles

Atrous Spatial Pyramid Pooling — du pixel au contexte global en un seul module

ASPP — Atrous Spatial Pyramid Pooling

Un taux unique de dilatation ne peut capturer local, moyen et global simultanément — l'ASPP le fait en parallèle

Conv 1×1 (r=1)

Champ réceptif
1×1 dans la feature map
→ Contexte strictement local
Sans dilatation
256 canaux de sortie

Conv 3×3 (r=6)

Champ réceptif
13×13 dans la feature map
208×208 px (OS=16)
→ Contexte local élargi
Ex : jambage, lettre

Conv 3×3 (r=12)

Champ réceptif
25×25 dans la feature map
400×400 px (OS=16)
→ Contexte moyen
Ex : ligne de texte

Conv 3×3 (r=18)

Champ réceptif
37×37 dans la feature map
592×592 px (OS=16)
→ Contexte large
Ex : bloc de texte, colonne

GAP — Global Avg.

1×1 (image entière)
Upsamplé à $H/16 \times W/16$
→ Contexte global total
Structure de la page
Illustrations, mise en page

Fusion des 5 branches → représentation multi-échelle

Concaténation des 5 sorties → $(H/16 \times W/16 \times 5 \times 256 = 1280 \text{ canaux})$

→ Conv 1×1 → 256 canaux · Upsampling bilinéaire ×16 → $(H \times W \times 256)$ · Conv 1×1 → n_{classes}

Chaque pixel reçoit un contexte local (traits d'encre), moyen (ligne) et global (structure de page) simultanément

4 & 5. DeepLabv3 et DeepLabv3+

Architecture complète · Le meilleur des deux mondes

DeepLabv3 — architecture complète

Chen et al., 2017 · ResNet modifié + ASPP + upsampling bilinéaire final

Architecture DeepLabv3

1. Backbone ResNet-50 ou 101 modifié
Output stride = 16 (ou 8)
Poids ImageNet conservés → transfert possible
2. Module ASPP sur la dernière feature map
Entrée : (B, 2048, H/16, W/16)
5 branches parallèles ($r=1, 6, 12, 18$, GAP)
Sortie : (B, 256, H/16, W/16)
3. Tête de classification (Conv 1×1)
(B, 256, H/16, W/16) → (B, n_classes, H/16, W/16)
4. Upsampling bilinéaire final $\times 16$
→ (B, n_classes, H, W) — carte de segmentation finale

Suppression du CRF post-traitement (vs v1/v2)
→ L'ASPP suffit pour la cohérence spatiale

Taux ASPP selon l'output stride

OS=16 : taux [6, 12, 18]

→ Champs réceptifs image : 208px, 400px, 592px

OS=8 : taux [12, 24, 36]

→ Mêmes champs réceptifs dans l'image originale
(les taux doivent être doublés car la feature map est $2\times$ plus grande)

Limite de DeepLabv3 — contours mous

L'upsampling bilinéaire $\times 16$ reste imprécis sur les contours

→ Bords des objets « mous » comparés à U-Net avec ses 4 skip connections

Même avec OS=8 ($\times 8$ upsampling), l'absence de décodeur fin limite la précision des contours de jambages et d'ascendants

→ Solution : DeepLabv3+ (section suivante)

DeepLabv3+ — le meilleur des deux mondes

Chen et al., 2018 · ASPP pour la multi-échelle + décodeur léger pour la précision des contours

Le décodeur léger de DeepLabv3+

Une seule skip connection depuis les features stride 4
(vs 4 niveaux dans U-Net)

1. Sortie ASPP : (B, 256, H/16, W/16)
→ Upsampling $\times 4$ → (B, 256, H/4, W/4)
2. Skip connection depuis couche1 (stride 4) :
(B, 256, H/4, W/4) → Conv 1×1 → (B, 48, H/4, W/4)
Projection à 48 canaux (légère)
3. Concaténation : (256 + 48 = 304 canaux à H/4)
→ Conv 3×3 + Conv 3×3 → 256 canaux (raffinement des contours)
→ Conv 1×1 → $n_classes$
→ Upsampling $\times 4$ → (B, $n_classes$, H, W)

Upsampling en 2 étapes : $\times 4$ vers stride 4, puis $\times 4$ final
vs 1 étape $\times 16$ dans DeepLabv3 → beaucoup plus précis

Pourquoi c'est mieux que v3 ?

L'upsampling $\times 4$ → $\times 4$ est beaucoup plus précis que $\times 16$ direct
La skip stride 4 (haute résolution) guide la reconstruction des contours
Le décodeur léger (2 Conv 3×3) affine localement sans coût majeur

Résultat : contours presque aussi précis que U-Net, avec le contexte global de l'ASPP

DeepLabv3+ vs U-Net — la synthèse

U-Net : 4 skip connections → reconstruction multi-niveau → contours excellents

DeepLabv3 : 0 skip → ASPP → contexte global → contours mous

DeepLabv3+ : 1 skip (stride 4) + ASPP → précision ET contexte

Pour les manuscrits : DeepLabv3+ recommandé pour la segmentation de layout

U-Net recommandé pour la détection de baselines et la binarisation

6. Entraînement et hyperparamètres

Taux de dilatation · Polynomial decay · LR différenciés backbone/ASPP

Champs réceptifs effectifs et schedule d'entraînement

*Les taux de dilatation doivent être adaptés à l'output stride ·
LR polynomial recommandé par les auteurs originaux*

Champs réceptifs effectifs dans l'image originale

Champ effectif = $(2r+1) \times \text{output_stride}$ pixels

OS=16, taux [6, 12, 18] :

$r=6 \rightarrow 13 \times 13$ feature map $\rightarrow 208 \times 208$ px image

$r=12 \rightarrow 25 \times 25$ feature map $\rightarrow 400 \times 400$ px image

$r=18 \rightarrow 37 \times 37$ feature map $\rightarrow 592 \times 592$ px image

OS=8, taux [12, 24, 36] — mêmes champs dans l'image :

$r=12 \rightarrow 25 \times 25$ feature map $\rightarrow 200 \times 200$ px image

(les taux doublent pour compenser la feature map plus grande)

Polynomial Decay LR Schedule

$$\text{lr}(t) = \text{lr}_0 \times (1 - t / T_{\text{max}})^{0.9}$$

Recommandé par les auteurs originaux de DeepLab

Décroissance rapide en début d'entraînement

puis progressive en fin — meilleure convergence que cosine

LR différenciés (SGD + momentum=0.9, weight_decay=4e-5) :

Backbone (couches 0-4) : $\text{lr} = 1\text{e-}3$

ASPP + tête : $\text{lr} = 1\text{e-}2$ (×10 plus élevé)

Pour fine-tuning sur manuscrits :

Backbone : $1\text{e-}4$ · ASPP : $1\text{e-}3$

Réglages recommandés pour la segmentation de layout sur manuscrits

Backbone : ResNet-50 pré-entraîné ImageNet · output_stride=16 · taux ASPP [6, 12, 18]

Batch size : 8-16 (OS=16) ou 4-8 (OS=8) · Polynomial decay · 50-100 epochs

Augmentations : crop 512×512, flips horizontaux légers, variations de luminosité/contraste simulant les dégradations de parchemin

Données min. recommandées : 200-300 pages annotées (vs 50-100 pour U-Net — DeepLab dépend davantage du pré-entraînement)

7. Comparaison et applications pour les manuscrits

U-Net vs DeepLabv3+ · Guide de décision · Application SegmOnto

Comparaison U-Net vs DeepLabv3+ pour les manuscrits

Critère	U-Net	Attention U-Net	DeepLabv3	DeepLabv3+
Précision des contours	Excellente (4 niveaux de skip)	Très bonne	Bonne	Très bonne
Contexte multi-échelle	Via la profondeur	+ Attention Gate	ASPP (excellent)	ASPP (excellent)
Données nécessaires	Peu (conçu pour peu de données)	Peu	Plus (ImageNet aide)	Plus
Paramètres	~31 M	~35 M	~44 M (ResNet-50)	~44 M
Segmentation de layout	Bonne	Bonne	Très bonne	Excellente ✓
Détection de lignes	Excellente ✓	Excellente ✓	Bonne	Très bonne
Binarisation	Bonne ✓	Meilleure ✓	Bonne	Très bonne

Guide de décision pour les manuscrits médiévaux

Quelle architecture pour quelle tâche ? — basé sur les propriétés de chaque paradigme

Binarisation (encre vs fond)

Recommandation : U-Net léger (features=[32,64,128,256])
Structures fines → peu de données · in_channels=3 (RGB) · dropout=0.2

Segmentation de lignes (baselines)

Recommandation : U-Net standard
Structures longues et fines → skip connections nécessaires · BLLA de Kraken · Loss BCE+Dice · augmentation élastique

Segmentation de layout (colonnes, illustrations, marges)

Recommandation : DeepLabv3+ ou Attention U-Net
Contexte global important → ASPP idéal · < 500 pages : Attention U-Net · > 500 pages : DeepLabv3+ · 7 classes SegmOnto

Très peu de données (< 50 pages annotées)

Recommandation : U-Net + encodeur ResNet pré-entraîné
Geler couches 1-3, entraîner couches 4 + décodeur · segmentation-models-pytorch · LR différenciés

Récapitulatif — DeepLab et convolutions dilatées

Convolution dilatée

$$y[i] = \sum x[i + r \cdot k] \cdot w[k]$$

9 paramètres (noyau 3×3) quel que soit r

Champ réceptif effectif =

$$(2r+1) \times (2r+1)$$

padding = r (pour noyau 3×3)

Clé de DeepLab :

→ Champ réceptif élargi

→ Résolution conservée

→ Même nombre de paramètres

ASPP (v2/v3)

5 branches en parallèle :

Conv 1×1 (local)

Conv 3×3 r=6 (champ 208px)

Conv 3×3 r=12 (champ 400px)

Conv 3×3 r=18 (champ 592px)

GAP (global)

→ Contexte local → global
en un seul module
→ Clé de la performance
en segmentation de layout

DeepLabv3+

ResNet modifié (OS=16)

+ ASPP (multi-échelle)

+ Skip stride 4 (48 canaux)

+ Décodeur léger (2× Conv 3×3)

+ Upsampling ×4 → ×4

Le meilleur des deux mondes :

→ ASPP : contexte global

→ Skip : contours précis

~44M paramètres

Recommandé : layout

SegmOnto

Applications HTR

Binarisation

→ U-Net léger RGB

Lignes (baselines)

→ U-Net standard

→ (BLLA Kraken)

Layout SegmOnto

→ DeepLabv3+

→ 7 classes

dhSegment (production)

→ ResNet + décodeur U-Net

→ Hybride des deux approches