

Synthèse architecturale

Choisir pour un projet réel

Panorama comparatif · Pipeline HTR · Questions ouvertes · Décisions architecturales

Objectif de la synthèse

Arrêter des choix architecturaux concrets pour le pipeline HTR · Discuter les questions ouvertes du TP

« En ingénierie, le meilleur outil n'est pas celui qui donne le score le plus élevé sur un benchmark — c'est celui qui résout le problème, dans les contraintes du projet, avec les ressources disponibles. »

Objectif pratique

Arrêter des choix architecturaux concrets pour chaque étape du pipeline HTR
Justifier ces choix au regard des contraintes (données, GPU, latence)
Ces décisions guideront les Jours 3 à 5

Objectif réflexif

Discuter les questions ouvertes soulevées par le TP et les cours
Ces questions n'ont pas de réponse unique
Elles appellent argumentation, nuances, acceptation de l'incertitude légitime

Ce cours conclut le Module 2 — rappel des sections précédentes

2.1 · Rappel CNN et biais inductifs 2.2 · Mécanisme d'attention et Vision Transformers 2.2b · U-Net avec et sans attention
2.2c · DeepLabv3 et convolutions dilatées 2.3 · TP segmentation et HTR (résultats empiriques)
→ Synthèse 2.4 : des fondements théoriques aux décisions opérationnelles pour le pipeline des Jours 3–5

1. Panorama comparatif des architectures

Cinq architectures · Critères généraux et spécifiques à l'HTR médiéval

Comparaison des caractéristiques générales

Critères opérationnels pertinents pour un projet de terrain — scores indicatifs issus de la littérature récente

Critère	ResNet-50	ViT-B/16	Swin-B	CRNN	TrOCR-base
Paramètres	25 M	86 M	88 M	~10 M	334 M
FLOPs (224 ²)	4,1 G	17,6 G	15,4 G	~2 G	—
ImageNet top-1	80,4%	81,8%	83,5%	—	—
Données (scratch)	~1 M	>10 M	>1 M	~100 k	>1 M
Fine-tuning petites don.	Très bon	Moyen	Bon	Bon	Très bon
Complexité spatiale	O(HW)	O(n ²)	O(n)	O(HW)	O(n ²)
Vitesse inférence CPU	Rapide	Lente	Moyenne	Très rapide	Très lente
Interprétabilité	Grad-CAM	Att. maps	Att. maps	Faible	Moyenne

Caractéristiques spécifiques à l'HTR sur manuscrits médiévaux

Ce qui compte sur le terrain — le classement ImageNet n'est pas un proxy fidèle de ces critères

Critère	ResNet-50	ViT-B/16	Swin-B	CRNN	TrOCR-base
Champ réceptif sur ligne	Local (limité)	Global	Semi-global	Global (BiLSTM)	Global
Gestion des ligatures	Faible	Bonne	Bonne	Bonne	Très bonne
Robustesse à l'inclinaison	Faible	Moyenne	Bonne	Moyenne	Bonne
Gestion des abréviations	Nulle	Via contexte	Via contexte	Via BiLSTM	Via LM decoder
Sensibilité au bruit	Élevée	Faible-moy.	Faible	Moyenne	Faible
Modèles médiévaux dispo.	Peu	Peu	Peu	Kraken ✓	HTR-United ✓
Fine-tuning (nb lignes)	~5 k images	~2 k lignes	~2 k lignes	~500 lignes	~500–2 k lignes

2. Le pipeline HTR

Choix architecturaux

De l'image au texte — justification de chaque décision architecturale

Le pipeline HTR — vue d'ensemble des choix architecturaux

Scan → Texte balisé en 6 étapes · Chaque étape a ses contraintes propres

Prétraitement

OpenCV + Sauvola

Algorithmique, pas de données, latence minimale

*Alt. : DocUNet
(dégradations extrêmes)*

Layout (zones)

SAM (ViT-H, zero-shot)

Aucune annotation requise · 1 Md de masques · Prompts interactifs pour corrections

Alt. : Swin-B + UperNet (si données disponibles)

Segmentation lignes

Kraken (baselines)

Spécialisé manuscrits · Baselines courbées · Modèles médiévaux HTR-United

Alt. : DINO + clustering (layouts non standard)

HTR par ligne

TrOCR fine-tuné

Contexte global (BEiT) · Modèle de langue GPT-2 · Abréviations médiévales

Alt. : Kraken HTR-LSTM (si contrainte CPU)

Illustrations

CLIP → LLaVA

Zero-shot · Descriptions naturelles · Flexibilité iconographique

Alt. : Florence-2

Export

JSON + TEI optionnel

Compatibilité humanités numériques · Interopérabilité eScriptorium

Alt. : PAGE XML

TrOCR vs Kraken : le choix HTR en détail

Deux paradigmes pour la même tâche : décodeur autorégressif vs CTC · L'approche ensemble combine les deux

Critère	TrOCR	Kraken HTR
CER moyen (corpus médiéval)	8–15%	10–20%
Vitesse (GPU)	~50 lignes/s	~200 lignes/s
Vitesse (CPU)	~2 lignes/s	~20 lignes/s
Fine-tuning nécessaire	~1 000 lignes	~500 lignes
Modèles médiévaux	À fine-tuner	HTR-United ✓
Modèle de langue implicite	GPT-2 ✓	Non (CTC)
Abréviations médiévales	Très bonne	Bonne
Inférence sans GPU	Difficile	✓

Règle de décision

< 500 lignes annotées → CTC (CRNN/Kraken)
Texte très abrégé / ambigu → TrOCR (contexte)
Contrainte temps réel → CTC (une passe)
Haute qualité (édition académique) → TrOCR
Script non latin ou rare → Kraken (alphabet flexible)

Approche ensemble recommandée

Vote pondéré TrOCR + Kraken
→ Complémentarité des types d'erreurs
→ TrOCR fort sur abréviations et contexte
→ Kraken fort sur vitesse et scripts rares
→ CER ensemble souvent inférieur aux deux seuls
→ Robustesse en production

3. Questions ouvertes

Six questions soulevées par le TP — sans réponse unique, avec des éléments d'argumentation

CNN encore pertinents ?

Q1 — Faut-il toujours l'architecture la plus performante ?

Le benchmark $\neq$ le problème. ImageNet top-1 $\neq$ CER sur parchemins médiévaux.

4 critères ordonnés pour décider :

1. Est-elle adaptée au problème et à ses contraintes propres ?
2. Dispose-t-on des ressources pour l'entraîner et la déployer ?
3. Existe-t-il des données et des modèles pré-entraînés dans le domaine ?
4. Quelle est sa performance effective sur les données du projet ?

Idée reçue à déconstruire :

« Plus grand = meilleur » $\rightarrow$ Non.

GPT-4 est meilleur que distilBERT en absolu.

distilBERT est optimal pour la classification de sentiment sur mobile à 5 ms.

La question : optimal sous quelles contraintes ?

Q2 — Les CNN sont-ils dépassés pour les documents ?

Non — ils sont adaptés à un sous-ensemble de tâches et de contraintes.

ConvNeXt (2022) : CNN modernisé (GELU, LayerNorm, grands noyaux 7×7) $\rightarrow$ performances Swin-comparables sur ImageNet. La frontière CNN/ViT s'estompe.

Avantage CNN sur petites données :

Le biais de localité favorise la convergence quand les données sont rares (< 500 lignes). Les CRNN restent pertinents dans ce cas.

Supériorité tâche-dépendante :

Classification de type de document $\rightarrow$ ResNet-50 suffit (4 $\times$ moins coûteux que ViT)

HTR sur lignes cursives complexes $\rightarrow$ Transformers avantageés (contexte global)

Idée reçue : « Les Transformers remplacent toujours les CNN » $\rightarrow$ La convergence vers les architectures hybrides suggère que les deux coexistent et s'hybrident.

Interprétabilité · CNN/ViT pertinent en 2026 ?

Q5 — L'interprétabilité des attention maps est-elle réelle ?

L'attention n'est pas l'explication (Jain & Wallace, 2019) :
On peut modifier les poids d'attention sans changer la prédiction.
L'attention est corrélée avec ce qui compte, pas causalement responsable.

L'Attention Rollout est une approximation :
Le mélange 50/50 attention/identité est arbitraire.
Chefer et al. (2021) proposent une relevance propagation plus précise mais coûteuse.

Cas où l'attention est trompeuse :
Un modèle peut « regarder » la fin de ligne pour prédire la ponctuation → corrélation positionnelle, pas compréhension syntaxique.

Utilité pratique malgré les limites :
→ Identifier les zones systématiquement ignorées
→ Détecter les erreurs de segmentation en amont
→ Comparer qualitativement des modèles
Faithfulness vs plausibility : les attention maps sont plausibles mais rarement fidèles au sens strict.

Q6 — La frontière CNN/ViT s'efface-t-elle en 2025–2026 ?

Convergence des design choices (ConvNeXt) :
En adoptant les choix de Swin (LayerNorm, GELU, moins de downsampling), un ResNet devient Swin-comparable sans changer le mécanisme fondamental. Les design choices comptent autant que le mécanisme.

Ce qui reste structurellement différent :
→ Complexité : $O(n^2)$ attention vs $O(HW)$ convolution
→ Biais inductif : localité/partage vs flexibilité contextuelle

Architectures émergentes :
Mamba/SSM (Gu & Dao, 2023) : complexité linéaire en n
VMamba, Vision Mamba : adaptation à la vision 2D
→ Potentiellement disruptif pour l'attention quadratique

Pour les manuscrits :
Sensibilité à la position + contexte global + robustesse → profil Transformer
L'architecture spécifique importe moins que son adéquation aux contraintes du problème

4. Récapitulatif des décisions architecturales

Ces choix guideront les Jours 3 à 5 — ils restent révisables à la lumière des résultats expérimentaux

Décisions architecturales et perspectives

Étape	Architecture	Raison principale	Alternative
Prétraitement	OpenCV + Sauvola	Efficace, aucune donnée nécessaire	<i>DocUNet (dégradations extrêmes)</i>
Layout	SAM (ViT-H)	Zero-shot, robuste, 1 Md de masques	<i>Swin-B + UperNet (si données)</i>
Lignes	Kraken segment	Spécialisé manuscrits, baselines courbées	<i>DINO + clustering</i>
HTR	TrOCR fine-tuné	Contexte global, modèle de langue GPT-2	<i>Kraken HTR (si contrainte CPU)</i>
Ensemble	Vote pondéré TrOCR + Kraken	Complémentarité des erreurs, robustesse	—
Illustrations	CLIP → LLaVA	Zero-shot, descriptions naturelles	<i>Florence-2</i>
Export	JSON + TEI optionnel	Compatibilité humanités numériques	<i>PAGE XML</i>

Ces choix ne sont pas définitifs — le Jour 5 (évaluation et robustesse) permettra de les remettre en question à la lumière des résultats expérimentaux. · Architecture demain ? Mamba/SSM (complexité linéaire), architectures hybrides CNN-ViT, foundation models (GPT-4V, Claude) en zero-shot — l'évolution reste ouverte.