

COURS 4.1 : PRÉTRAITEMENT DE SCANS DE MANUSCRITS

Module 4 · Computer Vision appliquée aux manuscrits médiévaux · MD5

RAPPEL PROBLÉMATIQUE À PRÉ-TRAITER

- **Page penchée** ou lignes inclinées → baisse des performances HTR.
- **Parchemin jauni de manière non uniforme** ou taches d'humidité → contraste local variable.
- **Encre du verso visible par transparence** (show-through) → bruit structuré.
- **Ombre de la reliure** sur la zone intérieure de la page → gradient d'éclairement.



Chaque correction a un coût : perte de détails fins, artefacts, ou temps de calcul. Le prétraitement n'est jamais neutre.

1. ANATOMIE D'UN SCAN DE MANUSCRIT MÉDIÉVAL

1.1 PROPRIÉTÉS DU PARCHEMIN

- **Translucidité** : la lumière traverse partiellement la feuille → le texte du verso apparaît en miroir (*show-through*).
- **Jaunissement non uniforme** : les bords vieillissent plus vite que le centre → gradient de fond.
- **Dégradations locales** : taches d'humidité, moisissures, piqûres d'insectes, grattages, réparations.

1.2 PROPRIÉTÉS DE L'ENCRE MÉDIÉVALE

- **Encre ferro-gallique** : noire à l'origine, brunit et devient corrosive → peut percer le parchemin (trous, texture irrégulière).
- **Encres colorées** : cinabre (rouge), azurite (bleu), or en feuille → forte saturation.
- **Palimpsestes** : traces du texte gratté encore visibles (bruit supplémentaire).

2. LA DÉFORMATION GÉOMÉTRIQUE ET SA CORRECTION

2.1 LES SOURCES DE DÉFORMATION

2.2 DESKEWING (REDRESSEMENT DE L'INCLINAISON)

Principe : estimer l'angle de rotation qui maximise la variance de la projection horizontale des pixels d'encre. Trois méthodes principales:

- **Analyse de Profils de Projection**: Calcule la somme des pixels noirs pour chaque ligne horizontale à différents angles. L'angle optimal maximise les pics de cette projection.
- **Transformée de Hough**: Détecte les lignes droites dans l'image et mesure leur orientation majoritaire.
- **Analyse dans le Domaine Fréquentiel**: Utilise la Transformée de Fourier. L'angle de rotation se traduit par une orientation spécifique des hautes fréquences dans le spectre de Fourier **Limites** : ne corrige que les inclinaisons globales uniformes ; échoue sur la courbure de reliure.


2.2.A DESKEWING PAR ANALYSE DE PROFILS DE PROJECTION

- **Principe** : on projette l'image binarisée sur l'axe vertical (somme des pixels d'encre (noirs) par ligne), et on mesure la **variance** de cette projection.
- Pour chaque angle testé (θ), on tourne l'image et on calcule la variance. L'angle qui maximise la variance correspond à l'horizontalité des lignes de texte.
- La variance est maximale quand les lignes sont parfaitement horizontales : les pics de projection sont alors les plus marqués.


Avantages : simple à comprendre,
🔥 efficace pour des textes simples avec peu de déformations.

Inconvénients : limité aux petites inclinaisons (inférieur à 10°), lent si plage angulaire large, peu robuste sur documents complexes (figures, colonnes, manuscrits très bruités).

angle:-9, median:344.5512532564715



angle:-8, median:345.2930961700921




angle:-7, median:345.8561526533507



angle:-6, median:345.1524165214348



angle:-5, median:344.23118000482555



2.2.B DESKEWING PAR TRANSFORMÉE DE HOUGH

- **Principe** : on détecte les **lignes droites** dans l'image (souvent après binarisation et détection de contours). (`cv2.HoughLines`)
- La transformée de Hough accumule dans un espace des paramètres (r, θ) les droites candidates. L'angle le plus fréquent (pic) donne l'orientation dominante du texte.
- On utilise généralement les contours des mots ou des lignes de base.

🔥 **Avantages** : robuste aux artefacts locaux, peut gérer des angles plus grands (jusqu'à 30°), bien adapté aux documents imprimés avec marges rectilignes.

Inconvénients : coût computationnel élevé sur grandes images, sensible à la présence de lignes parasites (réglures, encadrements, ombres de reliure).

Kew corrected by [2.24620502] degrees

Input image

Detected lines




2.2.C DESKEWING PAR ANALYSE DANS LE DOMAINE FRÉQUENTIEL (FFT)

- **Principe** : on calcule la **Transformée de Fourier rapide (FFT)** de l'image binarisée.
- Dans le spectre de Fourier (image des fréquences spatiales), les **hautes fréquences** correspondant aux détails d'encre sont orientées perpendiculairement aux lignes de texte.
- L'angle dominant du texte apparaît comme une **ligne radiaire** dans le spectre (perpendiculaire aux traits). On le détecte par transformée de Radon ou par analyse des pics.

🔥 **Avantages** : très robuste aux bruits et dégradations, gère de grands angles (jusqu'à 45°), précis même sur documents complexes.

Inconvénients : calcul plus lourd (nécessite FFT sur l'image entière), implémentation plus complexe.



```
from jdeskew.estimator import get_angle
angle = get_angle(image)
```

```
from jdeskew.utility import rotate
output_image = rotate(image, angle)
```


DIAGNOSTIC D'INCLINAISON

- **Ce qu'on regarde** : l'angle d'inclinaison global de la page .
- **Comment mesurer** : variance de la projection horizontale après rotation à différents angles. L'angle optimal maximise cette variance. Méthodes de référence :
 - `estimer_angle_inclinaison()` → retourne un angle en degrés.
 - Avec `jdeskew:angle = get_angle(image)`.
- **Seuil de décision** :
 - inférieur à 0.3° : on **ne corrige pas** (évite flou de rééchantillonnage inutile).
 - jusqu'à 10° → inclinaison modérée → on **corrige**.
 - au delà de 10° → probable erreur de détection (page très inclinée ou présence d'illustrations) → on **corrige avec prudence** ou on signale pour révision manuelle.
- **Risques de la correction** : flou de rééchantillonnage, coupure de bords, artefacts sur les zones saturées.



Règle pratique : toujours calculer l'angle avant correction ; si la variance maximale est peu

marquée (pic plat), la confiance est faible → laisser l'image brute ou passer en mode manuel.

Utilise une homographie à partir des quatre coins de la page (détection automatique ou manuelle).

```
H = cv2.getPerspectiveTransform(coins_source, coins_cible)
corrigee = cv2.warpPerspective(image, H, (largeur, hauteur))
```



Cette transformation redresse les pages photographiées en biais. Elle suppose que la

page est plane – faux en cas de forte courbure.

3. L'AMÉLIORATION DU CONTRASTE : CLAHE (CONTRAST LIMITED ADAPTIVE HISTOGRAM EQUALIZATION)

3.1 LE PROBLÈME DE L'ÉCLAIRAGE NON UNIFORME

- **Problème** : l'éclairage des manuscrits numérisés est rarement uniforme.
 - **Vignettage** : bords plus sombres que le centre.
 - **Ombre de reliure** : zone centrale assombrie.
 - **Gradient directionnel** : éclairage latéral.
- **Limite pour les manuscrits** : une zone de fond déjà claire peut devenir trop claire (perte de détails), une zone d'encre pâlie peut être noyée.

3.2 LE PRINCIPE DE CLAHE (CONTRAST LIMITED ADAPTIVE HISTOGRAM EQUALIZATION)

- Divise l'image en **tuiles** (ex. 8×8) et égalise l'histogramme **indépendamment** dans chaque tuile.
- Évite l'amplification du bruit en **limitant le contraste** (clipLimit) : les parties de l'histogramme qui dépassent le seuil sont redistribuées uniformément.
- Après égalisation locale, on interpole entre les tuiles pour éviter les frontières visibles.

```
clahe = cv2.createCLAHE(clipLimit=2.0, tileGridSize=(8,8))  
l_eq = clahe.apply(l)
```



3.2.3 DÉCIDER D'APPLIQUER CLAHE : DIAGNOSTIC D'UNIFORMITÉ DU CONTRASTE

Ce qu'on regarde : la variation locale de luminosité du fond, la présence d'ombres (reliure) ou de gradient directionnel.

- **Comment mesurer** :
 - Écart-type des pixels clairs (par ex. ceux $>$ percentile 75) : `std_fond`.
 - Métrique : `uniformite_fond = 1 - std_fond / 255`. Plus la valeur est faible, plus le fond est hétérogène.
- **Seuil de décision** :
 - inférieur à 0.4 → **CLAHE nécessaire**
 - entre 0.4 et 0.7 → **CLAHE avec clipLimit faible** (1.5–2.0).
 - supérieur → **pas de CLAHE** (gain nul, risque d'amplification du bruit).
- Appliquer CLAHE **uniquement** si l'histogramme local varie significativement d'une zone à l'autre.

4. LA RÉDUCTION DU BRUIT

4.1 LES TYPES DE BRUIT DANS LES SCANS DE MANUSCRITS

- **Bruit sel-et-poivre** : pixels isolés anormalement clairs (255) ou sombres (0).
Origine : poussières, défauts capteur, petites perforations.
- **Bruit gaussien** : fluctuations aléatoires de faible amplitude sur tous les pixels.
Origine : bruit thermique, compression JPEG. Aspect de « grain » uniforme.
- **Bruit structuré** : artefacts avec organisation spatiale (quadrillage JPEG, lignes de réglure, show-through du verso). Non aléatoire.

4.1.A LE FILTRE MÉDIAN : EFFICACE CONTRE LE SEL-ET-POIVRE

Principe : remplace chaque pixel par la **valeur médiane** de son voisinage. Contrairement au filtre moyen, il est robuste aux valeurs extrêmes.

```
def filtrer_bruit_sel_poivre(image: np.ndarray, ksize: int = 3) -> np.ndarray:  
    return cv2.medianBlur(image, ksize)
```

- `ksize` : taille du noyau (doit être impair, 3 ou 5).
- `ksize=3` : élimine les pixels isolés sans flouter les traits fins.
- `ksize=5` : élimine les taches plus larges mais commence à flouter les déliés.

Précaution manuscrits : les déliés gothiques et points diacritiques font 1-3 pixels. Utiliser `ksize=3` par défaut.

4.1.B DÉCIDER D'APPLIQUER UN FILTRE MÉDIAN : DIAGNOSTIC DE BRUIT SEL-ET-POIVRE

- **Ce qu'on regarde** : la présence de pixels isolés très sombres (0) ou très clairs (255) sur des zones normalement uniformes (fond ou traits d'encre).
- **Comment mesurer** :
 - Fraction de pixels extrêmes sur image en niveau de gris < 2 ou > 253
- **Seuil de décision** :
 - inférieur à 0.1% → bruit négligeable → **pas de filtre médian**.
 - jusqu'à 1% → bruit léger → **ksize=3**.
 - supérieur à 1% → bruit important → **ksize=5** mais risque d'effacer les déliés.

Risques : effacement des points diacritiques, extrémités de lettres, et des traits très fins (1 pixel). Toujours vérifier sur une zone d'écriture dense.

Règle pratique : commencer par `ksize=3` ; si le bruit persiste, augmenter à `ksize=5` **uniquement** si aucun détail critique n'est perdu. Le filtre médian s'applique **avant** binarisation.

4.2.A LE FILTRE GAUSSIEN : POUR LE BRUIT DE FOND

Principe : convolution avec un noyau gaussien. Atténue les hautes fréquences (variations pixel à pixel) mais floute les contours.

```
def filtrer_bruit_gaussien(image: np.ndarray, sigma: float = 0.8) -> np.ndarray:  
    return cv2.GaussianBlur(image, (0, 0), sigmaX=sigma, sigmaY=sigma)
```

- $\sigma < 1.0$: effet très léger, préserve les détails.
- $\sigma > 2.0$: flou significatif, perte des fins traits.

Utiliser un filtre gaussien **avant** binarisation pour lisser les variations de fond. Ne pas utiliser après binarisation.

DE FOND

- **Ce qu'on regarde** : la présence d'un grain uniforme (bruit haute fréquence) sans structure spatiale, souvent dû à la compression JPEG ou au bruit thermique.
- **Comment mesurer** :
 - Rapport signal/bruit : comparer l'écart-type d'une zone de fond (σ_{fond}) à celui d'une zone d'encre (σ_{encre}). Un bruit important augmente les deux.
- **Seuil de décision** :
 - inférieur à 5 → bruit très faible → **pas de filtre gaussien**.
 - jusqu'à 15 → bruit modéré → **sigma=0.5-0.8**.
 - supérieur à 15 → bruit élevé → **sigma=1.0-1.5** (mais risque de flou).
- **Risques** : atténuation des contours des lettres, perte de netteté. Ne jamais appliquer après binarisation.

Règle pratique : préférer le filtre médian pour le sel-et-poivre ; le filtre gaussien n'est utile que si le bruit est homogène et non impulsionnel. Commencer avec $\sigma=0.5$ et augmenter progressivement.

BIBLIOGRAPHIE DE RÉFÉRENCE

TRAITEMENT DES IMAGES DE DOCUMENTS ANCIENS

- **Sauvola, J., Pietikäinen, M.** (2000). *Adaptive Document Image Binarization*. Pattern Recognition, 33(2), 225–236. : L'article fondateur du seuillage adaptatif de Sauvola. Formulation mathématique et justification sur les documents anciens.
- **Otsu, N.** (1979). *A Threshold Selection Method from Gray-Level Histograms*. IEEE Transactions on Systems, Man, and Cybernetics, 9(1), 62–66. : La méthode de seuillage automatique global la plus utilisée.
- **Stathis, P., Kavallieratou, E., Papamarkos, N.** (2008). *An Evaluation Technique for Binarization Algorithms*. Journal of Universal Computer Science, 14(18). : Comparaison systématique des méthodes de binarisation sur des documents historiques.
- **Clausner, C., Antonacopoulos, A., Plotschacher, S.** (2019). *ICDAR2019 Competition on Recognition of Documents with Complex Layouts (RDCL2019)*. ICDAR 2019. : Évaluation standard des pipelines de segmentation de layout sur documents complexes.

DÉGRADATIONS ET RESTAURATION DES MANUSCRITS

- **Tonazzini, A., Gerace, I., Martinelli, F.** (2010). *Multichannel Blind Separation and Deconvolution of Images for Document Analysis*. IEEE Transactions on Image Processing, 19(3). : Séparation du show-through par ICA dans les images de manuscrits.
- **Fernandez-Maloigne, C., Robert-Inacio, F., Macaire, L.** (dir.) (2012). *Digital Color Imaging*. Wiley-ISTE. Chapitre 10 : *Color in Cultural Heritage Imaging*. : Les propriétés optiques spécifiques des documents patrimoniaux.
- **Stork, D. G., Duarte, M.** (2009). *Image Analysis for Art Conservation and Authentication*. Dans : *Image Processing for Artist Identification*. Springer. : Techniques d'imagerie multispectrale pour les manuscrits.

DÉWARPING ET CORRECTION GÉOMÉTRIQUE

- **Ma, K., Shu, Z., Bai, X., Wang, J., Samaras, D.** (2018). *DocUNet: Document Image Unwarping via a Stacked U-Net*. CVPR 2018. [arXiv:1804.01277] : Déwarping par réseau neuronal, état de l'art.
- **Xie, G. et al.** (2021). *DewarpNet: Single-Image Document Unwarping With Stacked 3D and 2D Regression Networks*. ICCV 2019. [arXiv:1909.09741] : Alternative à DocUNet, souvent plus performante.

BENCHMARKS ET DATASETS DE BINARISATION

- **Pratikakis, I., Zagoris, K., Karagiannis, X., Tsochatzidis, L., Mondal, T., Marthot-Santaniello, I.** (2019). *ICDAR 2019 Competition on Document Image Binarization (DIBCO 2019)*. ICDAR 2019. : Le benchmark de référence pour l'évaluation des méthodes de binarisation de documents.
- **Tensmeyer, C., Martinez, T.** (2017). *Document Image Binarization with Fully Convolutional Neural Networks*. ICDAR 2017. : Introduction des réseaux de neurones profonds pour la binarisation de documents.

CLAHE ET AMÉLIORATION DU CONTRASTE

- **Pizer, S. M. et al.** (1987). *Adaptive Histogram Equalization and Its Variations*. Computer Vision, Graphics, and Image Processing, 39(3), 355–368. : CLAHE : l'article fondateur.
- **Zuiderveld, K.** (1994). *Contrast Limited Adaptive Histogram Equalization*. Dans : *Graphics Gems IV*. Academic Press. : Implémentation pratique de CLAHE, référence pour OpenCV.

CODICOLOGIE ET MATÉRIAUX DES MANUSCRITS

- **Rück, P.** (éd.) (1991). *Pergament: Geschichte, Struktur, Restaurierung, Herstellung*. Thorbecke, Sigmaringen. : Référence technique sur le parchemin et ses propriétés physiques.
- **Bicchieri, M., Monti, M., Piantanida, G., Sannino, A.** (2013). *A non-invasive multi-technique survey of manuscripts: the case of the Beatus Vir*. *Spectrochimica Acta*. : Exemple de caractérisation multi-spectrale des encres et supports de manuscrits médiévaux.